

Optimización Tarea 3

Francisco Javier Peralta Ramírez

1. Escribe la expansión de Taylor de segundo orden para

$$f(\mathbf{x}) = 100(x_2 - x_1^2)^2 + (1 - x_1)^2 \quad \mathbf{x} \in \mathbb{R}^2$$

a) La expansión de Taylor de segundo orden para variables multidimensionales se escribe como

$$f(\mathbf{x}) \approx f(\mathbf{a}) + Df(\mathbf{a})(\mathbf{x} - \mathbf{a}) + \frac{1}{2}Hf(\mathbf{a})(\mathbf{x} - \mathbf{a})$$

Donde $Hf(\mathbf{a}) = DDf(\mathbf{a})$. es decir la *matriz Hessiana*.

b) En el caso de nuestra función, podemos calcular la primera derivada y el Hessiano

$$Df(\mathbf{x}) = (400(x_2 - x_1^2)x_1 + 2(1 - x_1) \quad 200(x_2 - x_1^2))$$

$$Hf(\mathbf{x}) = \begin{pmatrix} 400x_2 - 600x_1^2 - 2 & 400x_1 \\ 400x_1 & 200 \end{pmatrix}$$

Ahora podemos substituir en la formula anterior

$$f(\mathbf{x}) \approx f(\mathbf{a}) + \begin{pmatrix} 400(a_2 - a_1^2)a_1 + 2(1 - a_1) \\ 200(a_2 - a_1^2) \end{pmatrix}^T \begin{pmatrix} x_1 - a_1 \\ x_2 - a_2 \end{pmatrix} + \frac{1}{2} \begin{pmatrix} 400x_2 - 600x_1^2 - 2 & 400x_1 \\ 400x_1 & 200 \end{pmatrix} \begin{pmatrix} x_1 - a_1 \\ x_2 - a_2 \end{pmatrix}$$

2. Supngamos que observamos m valores de una función g en los puntos x_1, x_2, \dots, x_m por lo que conocemos los valores de $g(x_1), g(x_2), \dots, g(x_m)$. Queremos aproximar la función $g(\cdot) : \mathbb{R} \rightarrow \mathbb{R}$ por un polinomio

$$h_n(x) = a_0 + a_1x + a_2x^2 + \dots + a_nx^n$$

con $n < m$

Para aproximar la función queremos minimizar el error dado por

$$E = \sum_{i=1}^m (g(x_i) - h(x_i))^2$$

Lo caul se puede hacer resolviendo el sistema de ecuaciones dado por $DE = \mathbf{0}$ donde derivamos E con respecto a $[a_1, a_2, \dots, a_n]$

a) Genera observaciones del modelo

$$g(x) = \frac{\sin(x)}{x} + \eta \quad x \in [0.1, 10]$$

Donde $\eta \sim \mathcal{N}(0, 0.1)$ $0.1 = x_1 < x_2 < \dots < x_m = 10$.

b) Aproxima $g(\cdot)$ por $h_n(x)$ para $n = 2, \dots, 5$


$$h_2(x) = 1.067 - 0.373x + 0.029x^2$$

$$h_3(x) = 1.417 - 0.789x + 0.131x^2 - 0.006x^3$$


$$h_4(x) = 1.243 - 0.446x - 0.020x^2 + 0.016x^3 - 0.001165x^4$$

$$h_5(x) = 1.114 - 0.066x - 0.283x^2 + 0.086x^3 - 0.008886x^4 + 0.0003x^5$$


c) Grafica en la misma gráfica $h_n(x)$ para $n = 2, \dots, 5$ y $x_i, g(x_i), i = 1, 2, \dots, m$




(a) Polinomio grado 2



(b) Polinomio grado 3



(a) Polinomio grado 4



(b) Polinomio grado 5

3. Dada una $f(x)$ continua en $[a, b]$ encuentra el polinomio de aproximación de grado n

$$p_n(x) = a_0 + a_1x + a_2x^2 + \dots + a_nx^n$$

que minimiza

$$\int_a^b [f(x) - p(x)]^2 dx$$

Al igual que en el ejercicio anterior. Calculamos las derivadas parciales con respecto a $[a_0, a_1, \dots, a_n]$ y nos queda un sistema de ecuaciones.

$$\frac{\delta}{\delta a_0} = 2 \int_a^b f(x) - p(x) dx$$

$$\frac{\delta}{\delta a_i} = 2 \int_a^b x^i f(x) - x^i p(x) dx$$

Podemos igualar a cero y generar el sistema de ecuaciones:

$$\begin{pmatrix} \int_a^b 1 & \int_a^b x & \dots & \int_a^b x^n dx \\ \int_a^b x & \int_a^b x^2 & \dots & \int_a^b x^{n+1} dx \\ \vdots & \ddots & \ddots & \vdots \\ \int_a^b x^n & \int_a^b x^{n+1} & \dots & \int_a^b x^{2n} dx \end{pmatrix} \times \begin{pmatrix} a_0 \\ a_1 \\ \vdots \\ a_n \end{pmatrix} = \begin{pmatrix} \int_a^b f(x) \\ \int_a^b x f(x) \\ \vdots \\ \int_a^b x^n f(x) \end{pmatrix}$$

4. Para la distribución normal $\mathcal{N}(\mu, \sigma^2)$ que tiene una función de densidad de probabilidad

$$f(x|\mu, \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right)$$

La función de densidad de probabilidad correspondiente para una muestra $\{x_i\}_{i=1}^n$ de n variables independientes e idénticamente distribuidas es (verosimilitud):

$$\mathcal{L}(\mu, \sigma^2; x) = f(x_1, x_2, \dots, x_n | \mu, \sigma^2) = \prod_{i=1}^n f(x_i | \mu, \sigma^2)$$

Con $x = x_1, x_2, \dots, x_n$. Calcula

$$(\mu^*, \sigma^*) = \arg \max_{\mu, \sigma} \mathcal{L}(\mu, \sigma^2; x)$$

$$\arg \max_{\mu, \sigma} \mathcal{L}(\mu, \sigma^2; x) = (2\pi\sigma^2)^{(-n/2)} \exp\left(-\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2\right)$$

Podemos ver que el problema de máxima verosimilitud es el mismo que el de log verosimilitud. Por lo que el problema se puede ver como

$$\arg \max_{\mu, \sigma} l(\mu, \sigma^2; x) = -\frac{n}{2} \ln(2\pi) + \frac{n}{2} \sigma^2 + -\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2$$

Para encontrar el máximo, derivamos con respecto a μ y σ^2 e igualamos a 0

$$\frac{\delta}{\delta \mu} = \frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu) = 0$$

Esto sólo es cero cuando

$$\begin{aligned} \sum_{i=1}^n (x_i - \mu) &= 0 \\ \left(\sum_{i=1}^n x_i \right) - n\mu &= 0 \\ \mu &= \frac{1}{n} \sum_{i=1}^n x_i \end{aligned}$$

Lo cual equivale al promedio muestral. Y para σ^2

$$\begin{aligned} \frac{\delta}{\delta \sigma^2} &= -\frac{n}{2\sigma^2} + \left[\frac{1}{2} \sum_{i=1}^n (x_i - \mu)^2 \right] \left(-\frac{1}{(\sigma^2)^2} \right) = 0 \\ &= \frac{1}{2\sigma^2} \left[\frac{1}{\sigma^2} \sum_{i=1}^n (x_i - \mu)^2 - n \right] = 0 \end{aligned}$$

El cual es cero sólo cuando

$$\sigma^2 = \frac{1}{n} \sum_{j=1}^n (x_i - \mu)^2$$

Lo cual equivale a la varianza muestral

5. a) Suponga que $f : \mathbb{R} \rightarrow \mathbb{R}$ es convexa y $a, b \in \text{dom} f$ con $a < b$. Muestra que

$$a(f(x) - f(b)) + x(f(b) - f(a)) + b(f(a) - f(x)) \geq 0 \quad \forall x \in [a, b]$$

Podemos reescribir la formula como

$$f(x)(a - b) + f(b)(x - a) + f(a)(b - x) \geq 0$$

También podemos expresar x como $x = \alpha(a) + (1 - \alpha)b$. Substituimos en nuestra ecuación.

$$f(\alpha(a) + (1 - \alpha)b)(a - b) + f(b)(\alpha(a) + (1 - \alpha)b - a) + f(a)(b - \alpha(a) - (1 - \alpha)b) \geq 0$$

$$f(\alpha(a) + (1 - \alpha)b)(a - b) + f(b)(-a(1 - \alpha) + (1 - \alpha)b) + f(a)(-\alpha(a) - \alpha(b)) \geq 0$$

$$f(\alpha(a) + (1 - \alpha)b)(a - b) + f(b)((1 - \alpha)(b - a)) \geq \alpha f(a)(a - b)$$

$$f(\alpha(a) + (1 - \alpha)b)(a - b) \geq \alpha f(a)(a - b) + f(b)((1 - \alpha)(a - b))$$

Por definición, una función es convexa cuando

$$f[\alpha x_1 + (1 - \alpha)x_2] \leq \alpha f(x_1) + (1 - \alpha)f(x_2)$$

Como $(a - b) \leq 0$ se cumple que es convexa

b) Suponga que $f : \mathbb{R}^n \rightarrow \mathbb{R}$ es convexa con $A \in \mathbb{R}^{n \times m}$ y $b \in \mathbb{R}^n$. Muestra que la función $g : \mathbb{R}^m \rightarrow \mathbb{R}$ definida por $g(x) = f(Ax + b)$, con $\text{dom } g = \{x | Ax + b \in \text{dom } f\}$, es convexa.

Tomemos una $z = \alpha x + (1 - \alpha)y$

$$g(z) = g(\alpha x + (1 - \alpha)y) = f(\alpha Ax + (1 - \alpha)Ay + b)$$

$$g(z) = g(\alpha x + (1 - \alpha)y) = f(\alpha Ax + (1 - \alpha)Ay + (\alpha + (1 - \alpha))b)$$

$$g(z) = g(\alpha x + (1 - \alpha)y) = f(\alpha(Ax + b) + (1 - \alpha)(Ay + b))$$

Consideremos $x_2 = Ax + b$ y $y_2 = Ay + b$

$$g(z) = f(\alpha x_2 + (1 - \alpha)y_2)$$

Como f es convexa

$$g(\alpha x + (1 - \alpha)y) \leq \alpha f(x_2) + (1 - \alpha)f(y_2)$$

Substituimos valores

$$g(\alpha x + (1 - \alpha)y) \leq \alpha f(Ax + b) + (1 - \alpha)f(Ay + b)$$

Por lo que cumple el criterio de ser convexa